

Portraits de Reconnaissance Faciale Automatisée : Méthodes Deep Learning pour l'Analyse des Traits

INES KHELIFI^{1,*}

²iTeam University

*Corresponding author: khelifi.ines@gmail.com

Compiled May 30, 2022

La reconnaissance faciale est un domaine de recherche très actif au cours de ces dernières années. Initialement définie comme une branche de l'intelligence artificielle pour permettre aux robots de percevoir visuellement, elle fait maintenant partie d'une discipline plus généralisée et plus large de la vision par ordinateur. Les applications de la vision par ordinateur peuvent traiter des images s'étalant sur une large gamme du spectre électromagnétique. Les rayons X sont utilisés dans le domaine médical pour créer des images du corps humain sans avoir besoin de recourir à la chirurgie. Les rayons gamma et les ondes radio en imagerie par résonance magnétique (IRM) capturent des images de fines sections du corps humain utiles pour le diagnostic et le traitement des maladies [1]. On se propose dans cet article d'analyser différentes méthodes utilisées pour dresser les portraits de reconnaissances faciales automatisées. ©

2022 iTeam university Publishing Group

<http://dx.doi.org/10.1364/ao.XX.XXXXXX>

1. INTRODUCTION

La reconnaissance faciale présente plusieurs avantages par rapport à d'autres modalités biométriques telles que les empreintes digitales et l'iris : en plus d'être naturel et non intrusif, l'avantage le plus important du visage est qu'il peut être capturé à distance et de manière discrète.

Parmi les six attributs biométriques pris en compte par [2], les traits du visage ont obtenu le plus grand score dans un système de contrôle de passeport lisibles à la machine douanière MRTD¹ sur la base d'un certain nombre de facteurs d'évaluation tels que l'inscription, le renouvellement, les exigences de la machine et le public. La Reconnaissance faciale comme étant la base des technologies biométriques, est devenue de plus en plus importante en raison des progrès rapides des dispositifs de capture d'images (caméras de surveillance, caméra des téléphones mobiles), de la disponibilité d'énormes quantités d'images sur le Web et des exigences accrues en matière de sécurité.

La détection faciale consiste à la localisation d'un visage dans une image sans identification. Bien que de nombreux algo-

rithmes de détection de visage existaient avant 2001, une percée majeure dans la détection faciale est apparue avec l'article de Viola-Jones "Rapid Object Detection using a Boosted Cascade of Simple Features" [3, 4].

Contrairement aux méthodes de détection faciale précédentes qui reposaient sur l'analyse des pixels, Viola-Jones a conçu un algorithme appelé "Haar-classifier" qui s'appuyait sur des fonctionnalités de type Haar. Le classificateur de Haar est un algorithme d'apprentissage automatique formé avec de nombreux échantillons positifs et négatifs pour détecter des objets dans des images. Pour que le classificateur fonctionne correctement, la taille de l'image dans l'ensemble d'apprentissage doit être la même que la taille de l'image d'entrée utilisée pour la détection des objets.

2. ALGORITHMES

A. Algorithmes basés sur l'apparence

Les algorithmes basés sur l'apparence utilisent les données de pixels d'image dans leur ensemble pour la reconnaissance.

La corrélation directe, Eigen-face et Fisher-Face appartiennent à cette classe d'algorithmes. La corrélation directe utilise la comparaison directe des pixels d'image de deux images faciales, produisant un score de similarité [5, 6]. Contrairement à une méthode de corrélation directe qui utilise des images faciales dans leur espace d'image d'origine, les algorithmes Eigen-face et Fisher-face réduisent l'image au facteur le plus discriminant et effectuent la comparaison l'images dans un espace de dimension réduite [7, 8].

B. Algorithmes basés sur l'apparence active

Les algorithmes basés sur l'apparence active contiennent des informations statistiques sur une forme d'image et une variation de texture. Foulques et al. [9] ont appliqué une analyse en composantes principales (PCA) pour générer un modèle statistique qui localise les points de référence sur un ensemble d'images d'apprentissage. Les points de référence sont utilisés pour entraîner le modèle à apprendre la translation entre le paramètre du modèle synthétisé et les images test. Pour trouver les paires d'image et les faire correspondre entre eux, l'erreur résiduelle du modèle est mesurée par rapport aux changements prédits des paramètres actuels du modèle ce qui conduit à un meilleur ajustement et à une meilleure reconnaissance [10].

¹https://www.icao.int/meetings/tag-mrtd/tagmrtd22/tag-mrtd-22_wp24.pdf

C. Support Vector Machines

Les machines à vecteurs de support utilisent un ensemble d'images d'apprentissage pour calculer l'hyperplan de séparation optimal. Guo et al. [11] ont appliqué cette méthode à la reconnaissance faciale à l'aide d'une classification arborescente binaire, où les images faciales sont classées de manière itérative comme appartenant à l'une des deux classes qui se propagent dans une structure arborescente binaire jusqu'à ce qu'une décision finale de classification puisse être prise.




Fig. 1. SVM Classifier.

D. Algorithmes du modèle Bayésien

Les algorithmes du modèle bayésien montrent une mesure probabiliste de similarité dérivée d'une analyse bayésienne de la différence entre les images faciales. Le calcul des fonctions de probabilité utilisant les différences d'intensité d'image entre ensembles de données conduit à un score de similarité à partir de la règle de Bayes, qui peut ensuite être utilisé pour la classification de reconnaissance faciale [12].

E. Neural Networks

Les réseaux de neurones assurent le traitement de l'information, qui est similaire à la manière dont l'information est traitée dans des systèmes biologiques tels que le cerveau humain. Leur principale force est la capacité d'apprendre à partir d'exemples, la tolérance aux pannes et la robustesse. Ils sont adaptés à la reconnaissance de visages qui présentent beaucoup de variation et nécessitent cependant peu de modifications de l'algorithme de reconnaissance. Lawrence [13] décrit comment entraîner un classificateur de réseau neuronal pour l'identification et la reconnaissance faciale.

F. Algorithmes Basés sur la texture

Les algorithmes basés sur la texture extraient la texture dans les images, en divisant le visage en plusieurs régions. Le modèle binaire local (LBP) est un exemple d'algorithmes basés sur la texture, où les caractéristiques LBP pondérées sont extraites pour générer un vecteur de différentes caractéristiques. Deux vecteurs de caractéristiques LBP sont appariés en appliquant une mesure de distance Chi-carré pondérée [14].

G. Algorithmes Basés sur les caractéristiques

Ces algorithmes extraient un ensemble de caractéristiques géométriques tel que la distance à partir des images faciales et utilisent ces caractéristiques comme une référence pour comparer les images. L'analyse des caractéristiques locales est un exemple d'algorithmes basés sur les caractéristiques [15].

3. RECONNAISSANCE FACIALE AVEC KERAS

Dans ce chapitre on utilise un réseau de neurones convolutif (CNN) pour extraire les caractéristiques des images données en entrée. Le réseau suit l'approche décrite dans [16] avec des modifications inspirées du projet OpenFace. Keras est utilisé pour implémenter CNN, Dlib et OpenCV pour aligner les visages sur les images d'entrée. Les performances de reconnaissance faciale sont évaluées sur un petit sous-ensemble de l'ensemble de données LFW, qu'il est possible de remplacer par un ensemble de données personnalisé, par exemple, des images d'élèves inscrits dans l'université (pour une vérification biométrique à l'entrée).

A. Exemple d'implémentation de l'algorithme en utilisant SVM

Dans l'exemple de la figure 3, on utilise le classificateur SVM pour tester la reconnaissance faciale




Fig. 2. Image de Albert Einstein identifiée à l'aide de l'algorithme SVM.

4. ARCHITECTURE CNN ET ENTRAINEMENT

L'architecture CNN utilisée ici est une variante de l'architecture d'inception [17]. Plus précisément, il s'agit d'une variante de l'architecture CNN décrite dans [16] et identifiée comme modèle nn4.small2 qu'on nomme ici model.cnn dans le projet OpenFace. Dans ce chapitre, on se charge d'une implémentation Keras de ce modèle dont la définition est tirée du projet Keras-OpenFace. Les détails de l'architecture ne sont pas détaillés ici, il est seulement utile de savoir qu'il existe une couche entièrement connectée avec 128 unités cachées suivie d'une couche de normalisation L2 au-dessus de la base convolutive. Ces deux couches supérieures sont appelées la couche d'enrobage à partir de laquelle les vecteurs d'enrobage à 128 dimensions peuvent

être obtenus. Le modèle complet est décrit dans model.py.

La formation de modèle vise à apprendre une incorporation $f(x)$ d'une image x telle que la distance $L2$ au carré entre tous les visages de la même identité est petite et la distance entre une paire de visages d'identités différentes est grande. Ceci peut être réalisé avec une *perte de triplet* L qui est minimisée lorsque la distance entre une image d'ancrage x_i^a et une image positive x_i^p (de la même identité) dans l'espace d'intégration est inférieure à la distance entre cette image d'ancrage et une image négative x_i^n (identité différente) d'au moins une marge α .

$$L = \sum_{i=1}^m [\|f(x)_i^a - f(x)_i^p\|_2^2 - \|f(x)_i^a - f(x)_i^n\|_2^2 + \alpha]_+ \quad (1)$$

Durant la phase d'entraînement, il est important de sélectionner les triplets dont les paires positives (x_i^a, x_i^p) et négatives (x_i^a, x_i^n) sont difficiles à discriminer. C'est-à-dire que leur différence de distance dans l'espace d'encastrement doit être inférieure à la marge α sinon, le réseau est incapable d'apprendre une intégration utile. Par conséquent, chaque itération de formation doit sélectionner un nouveau lot de triplets en fonction des intégrations apprises lors de l'itération précédente.

A. Seuil de la distance

Pour trouver la valeur optimale de τ , la vérification des visages doit être évaluée sur une intervalle de distances. À une valeur de seuil donné, toutes les paires de vecteurs d'intégration possibles sont classées soit ayant la même identité ou soit ayant une identité différente et le tout comparé au résultat attendu. Puisque nous avons affaire à des classes asymétriques (beaucoup plus de paires négatives que de paires positives), nous utilisons le score F1 comme métrique d'évaluation au lieu de la précision.




Fig. 3. Distance Threshold.

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} = \frac{TP}{TP + \frac{1}{2} \times (FP + FN)} \quad (2)$$

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (3)$$

L'algorithme de reconnaissance faciale ici présente une précision de 0.991 à $\tau = 0.30$.

Ce n'est pas mal étant donné une ligne de base de 0.89 pour un classificateur qui prédit toujours une identité différente (il y a 450 paires positives et 3000 paires négatives), mais puisque nn4.small2.v1 est un modèle relativement petit, il est toujours inférieur à ce qui peut être atteint par les meilleurs modèles (> 0.99).

B. Classification KNN

Étant donné une estimation du seuil de distance τ , la reconnaissance faciale est maintenant aussi simple que de calculer les distances entre un vecteur d'intégration donné à l'entrée et tous les vecteurs d'intégration dans une base de données.

L'image donnée à l'entrée se voit attribuer une étiquette (c'est-à-dire une identité) d'entrée de la base de données avec la distance la plus petite si elle est inférieure à τ ou une étiquette inconnue dans le cas contraire.

Une approche plus robuste consiste à étiqueter les données à l'entrée en utilisant les entrées les mieux notées dans la base de données, ce qui représente essentiellement une classification KNN avec une métrique de distance euclidienne. Alternative-ment, une machine à vecteurs de support linéaire (SVM) peut être entraînée avec les entrées de la base de données et utilisée pour classer, c'est-à-dire identifier de nouvelles entrées. Pour la formation de ces classificateurs, nous utilisons 50 pourcents de l'ensemble de données et 50 pourcents pour l'évaluation.

C. KNN Algorithm

Algorithm 1. KNN algorithm

```

1: procedure KNN( $A, B, a, b$ ) ▷ train and test data
2:    $knn \leftarrow KNeighborsClassifier(nneighbors = 1, metric = 'euclidean')$ 
3:    $svc \leftarrow LinearSVC()$ 
4:    $mod1 \leftarrow knn.fit(A, a)$ 
5:    $mod2 \leftarrow svc.fit(A, a)$ 
6:    $KNN \leftarrow accuracy.score(b, knn.predict(B))$ 
7:    $SVC \leftarrow accuracy.score(b, svc.predict(B))$ 
8:   return KNN, SVC ▷ Accuracy Scores

```

$A : X.train, B : X.test, a : y.train, b : y.test$

D. Résultats

Dans notre exemple on voit que le classificateur KNN atteint une précision de 0.96 sur l'ensemble de test alors que le classificateur SVM atteint une précision de 0.98.

Bien que les deux algorithmes produisent des résultats satisfaisants en terme de score et précision. L'algorithme SVM offre un meilleur résultat avec une vitesse de classification nettement supérieure au KNN.

En effet, l'algorithme KNN utilise un système de vote pour déterminer à quelle classe appartient un objet non classé, en tenant compte de la classe de ses plus proches voisins

dans l'espace de décision. L'algorithme SVM par contre est extrêmement rapide, capable de classer des images aériennes de 12 mégapixels en environ dix secondes (contrairement au KNN qui prend entre quarante et cinquante secondes).

Généralement, l'algorithme KNN classe avec précision; cependant, il génère plusieurs petites erreurs de classification qui interfèrent avec l'image classifiée finale. Par contre, l'algorithme SVM classera parfois de manière erronée un objet volumineux qui interfère rarement avec l'image classifiée au final.

5. CONCLUSION D'ÉTUDE

La reconnaissance faciale est une méthode de reconnaissance biométrique présentant des caractéristiques pratiques dans les domaines de la sécurité nationale et sociale.

Avec l'approfondissement de la recherche sur la vision par ordinateur, la reconnaissance faciale à petite échelle a obtenu de bons résultats de performance. Par contre à l'avènement de l'ère Big Data, les méthodes de reconnaissance faciale à petite échelle ne sont plus en mesure de répondre aux besoins sociaux. De ce fait l'analyse des performance et de la précision des algorithmes de reconnaissance faciales appliquées aux méga données est devenu le nouveau point central de la recherche en intelligence artificielle.

6. OUVERTURE ET PERSPECTIVES

Les dernières années ont connu un intérêt croissant pour l'automatisation de la vision computationnelle ainsi que l'apprentissage machine et en particulier pour la sécurité publique et le besoin de techniques d'analyse et de modélisation faciale dans la gestion de données multimédia et numériques. Les recherches sur l'automatisation de la reconnaissance faciale ont commencé dans les années 1960 mais ce n'est que récemment qu'on a vu un essort significatif dans le développement et le deployment de systèmes de la vision par ordinateur.

Bien qu'une reconnaissance faciale précise et exacte offre toujours de nombreux défis pour les chercheurs, l'essor des technologies se voit rempli d'un éventail plus large de fonctions.

En effet, non seulement les technologies de vision par ordinateur sont plus faciles à mettre en place de nos jours mais elles pourront également discerner mieux des images dans des conditions qui posent défi à l'heure actuelle. Ces technologies peuvent être implémentées en parallèle avec l'intelligence artificielle AI pour créer des applications plus puissantes. Par exemple, la vision par ordinateur jouera un rôle essentiel dans le développement de l'intelligence artificielle générale AGI et de la super-intelligence artificielle ASI en leur donnant la capacité de traiter mieux l'information perçue aussi bien que le système visuel humain.

REFERENCES

1. C. H. Chen, "An introduction to computer vision in medical imaging," in *Computer Vision in Medical Imaging*, , vol. Volume 2 of *Series in Computer Vision* (WORLD SCIENTIFIC), pp. 1–16.
2. R. Heitmeyer, pp. 11,.
3. P. A. Viola and M. J. Jones, .
4. R. Lienhart and J. Maydt, .
5. R. Brunelli and T. Poggio, **15**, 1042.

6. A. V. Nefian, "Statistical approaches to face recognition," .
7. M. Turk, "A random walk through eigenspace," .
8. P. N. Belhumeur, J. P. Hespanha, and D. J. Kriegman, **19**, 10.
9. T. Cootes, K. Walker, and C. Taylor, "View-based active appearance models," in *Proceedings Fourth IEEE International Conference on Automatic Face and Gesture Recognition (Cat. No. PR00580)*, pp. 227–232.
10. W. Zhao, R. Chellappa, P. J. Phillips, and A. Rosenfeld, **35**, 399.
11. G. Guo, S. Li, and K. Chan, .
12. B. Moghaddam, T. Jebara, and A. Pentland, **33**, 1771.
13. S. Lawrence, C. Giles, A. C. Tsoi, and A. Back, **8**, 98. Conference Name: IEEE Transactions on Neural Networks.
14. T. Ahonen, A. Hadid, and M. Pietikainen, **28**, 2037. Conference Name: IEEE Transactions on Pattern Analysis and Machine Intelligence.
15. P. S. Penev and J. J. Atick, **7**, 477. Publisher: Taylor & Francis _eprint: https://doi.org/10.1088/0954-898X_7_3_002.
16. F. Schroff, D. Kalenichenko, and J. Philbin, "FaceNet: A unified embedding for face recognition and clustering," in *2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 815–823.
17. C. Szegedy, W. Liu, Y. Jia, P. Sermanet, S. Reed, D. Anguelov, D. Erhan, V. Vanhoucke, and A. Rabinovich, "Going deeper with convolutions," Type: article.

FULL REFERENCES

1. C. H. Chen, "An introduction to computer vision in medical imaging," in *Computer Vision in Medical Imaging*, vol. Volume 2 of *Series in Computer Vision* (WORLD SCIENTIFIC), pp. 1–16.
2. R. Heitmeyer, "Biometric identification promises fast and secure processing of airline passengers," pp. 11,.
3. P. A. Viola and M. J. Jones, "Rapid object detection using a boosted cascade of simple features," .
4. R. Lienhart and J. Maydt, "An extended set of haar-like features for rapid object detection," .
5. R. Brunelli and T. Poggio, "Face recognition: Features versus templates," **15**, 1042–1052.
6. A. V. Nefian, "Statistical approaches to face recognition," .
7. M. Turk, "A random walk through eigenspace," .
8. P. N. Belhumeur, J. P. Hespanha, and D. J. Kriegman, "Eigenfaces vs. fisherfaces: Recognition using class specific linear projection," **19**, 10.
9. T. Cootes, K. Walker, and C. Taylor, "View-based active appearance models," in *Proceedings Fourth IEEE International Conference on Automatic Face and Gesture Recognition (Cat. No. PR00580)*, pp. 227–232.
10. W. Zhao, R. Chellappa, P. J. Phillips, and A. Rosenfeld, "Face recognition: A literature survey," **35**, 399–458.
11. G. Guo, S. Li, and K. Chan, "Face recognition by support vector machines," .
12. B. Moghaddam, T. Jebara, and A. Pentland, "Bayesian face recognition," **33**, 1771–1782.
13. S. Lawrence, C. Giles, A. C. Tsoi, and A. Back, "Face recognition: a convolutional neural-network approach," **8**, 98–113. Conference Name: IEEE Transactions on Neural Networks.
14. T. Ahonen, A. Hadid, and M. Pietikainen, "Face description with local binary patterns: Application to face recognition," **28**, 2037–2041. Conference Name: IEEE Transactions on Pattern Analysis and Machine Intelligence.
15. P. S. Penev and J. J. Atick, "Local feature analysis: a general statistical theory for object representation," **7**, 477–500. Publisher: Taylor & Francis _eprint: https://doi.org/10.1088/0954-898X_7_3_002.
16. F. Schroff, D. Kalenichenko, and J. Philbin, "FaceNet: A unified embedding for face recognition and clustering," in *2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 815–823.
17. C. Szegedy, W. Liu, Y. Jia, P. Sermanet, S. Reed, D. Anguelov, D. Erhan, V. Vanhoucke, and A. Rabinovich, "Going deeper with convolutions," Type: article.